

Sign Language Retrieval:

текстовый поиск по корпусу записей на жестовом языке

Участники: Филипп Бурлаков, Алина Лобанова
Руководитель: Евгений Пищик
Команда: 81


Задача проекта



гуглить рецепт



4:58–5:32




0:51–1:02



3:29–3:40



давно



0:32–0:43



3:26–3:47



2:42–2:53

Цели на год



1. Сбор и разведочный анализ данных
2. Поиск существующих подходов
3. Применение бейзлайн-модели
4. Построение собственной модели ретривала
5. Создание сервиса

Данные

316 видео с субтитрами с канала Всероссийского общества глухих (VOGinfo) общей длительностью **55 часов**, из которых реплики на русском жестовом занимают **41 час**.



	videos	11-seconds video pieces
train	290	28818
valid		7205
test	22	2633

EDA: субтитры



EDA: видео

Мы брали только видео
размером 1280x720



Предобработка данных

кусочек № k



...



...



33 кадра, 11 секунд

15 кадров, 5 секунд

33 кадра, 11 секунд



...



...



кусочек № k+1

Метрики

1. Mean Reciprocal Rank (MRR)

$$MRR = \frac{1}{U} \sum_{v=1}^U \frac{1}{rank_v(s_v)}$$

U — количество текстов в корпусе

s_i — видео, соответствующие i -му тексту

$rank_i(vid)$ — ранг vid среди видео, отсортированных по релевантности i -му тексту

2. Hit Rate (Hit@k)

$$Hit@k = \frac{1}{U} \sum_{v=1}^U [rank_v(s_v) \leq k]$$

Бейзлайн

Мы хотели найти и применить готовую модель для этой задачи.

Такие модели есть для американского и немецкого жестовых (и соответствующих звучащих) языков, но они не выложены в опенсорс.


Поэтому применили модель **X-CLIP** от Microsoft для классического video-text retrieval.

	X-CLIP
<i>Hit@1</i>	0.00036
<i>Hit@100</i>	0.03801
<i>MRR</i>	0.00321

Попыток улучшить бейзлайн не было, но мы добыли GPU!

Сервисная часть

В будущем .pt файл с эмбедингами → база данных



Сервисная часть: EDA

app

localhost:8501

Bookmarks Яндекса Почта Карты Маркет Gmail YouTube Карты Перевести leed Twot rules Adobe Acrobat

Всё закладки

RUNNING... Stop Deploy

Enter your YaDisk Key:

.....

Enter your YaDisk path:

disk:/SLR Project/

Drop your JSON metadata:

Drag and drop file here
Limit 200MB per file • JSON

Browse files

test.json 3.0MB

A phrase feature to display distribution for:

Duration

Most popular text features to show:

Trigrams

11.005
11
10.995

values



Сервисная часть: поиск

app

localhost:5501

Bookmarks Яндекc Почта Карты Маркет Gmail YouTube Карты Перевести lexd Two rules Adobe Acrobat Все закладки

Deploy

num. of words
variable

Enter your query:

Привет

Enter maximum
vids:


2

Проект "История ВОГ в лицах".

Автор: Виктор Паленный
Съёмка и монтаж: Роман Парфёнов
Ведущий: Александр Сидельников

6:24 / 6:41

Контрастивное обучение




Принцип обучения – **контрастивный**:

- positive sampling
- negative sampling
- попробовать triplet loss, contrastive loss


Это не финальная версия модели, мы скорее всего будем пробовать разные архитектуры (cross-encoders VS bi-encoders, например)

Контрастивное обучение: эксперименты


val_loss



val_acc



train_loss



```
learning_rates = [0.1, 0.01, 0.001]
dropouts = [0.1, 0.2, 0.3, 0.4, 0.5, 0.7]
hidden_layer_dimensions = [512, 1024, 2048, 4096]
batch_size = 32
```

Контрастивное обучение: результаты

Лучшая модель на eval-сете:


learning_rate = 0.001

dropout = 0.2

hidden_layer_dimension = 4096

Eval accuracy: **0.061**

Test accuracy: **0.031**



Команда проекта



Филипп Бурлаков

- Парсинг youtube-видео
- EDA субтитров
- Бейзлайн-модель и её качество
- Frontend сервиса



Алина Лобанова

- Парсинг ссылок на youtube-видео
- EDA видео
- Создание датасета из сырых видео
- Backend сервиса